

1. 핵심 방향성

이번 태스크는 단순히 텍스트 임베딩을 추가해 성능을 높이는 문제가 아니라, **시계열 정보를 중심으로 두고 텍스트 정보를 어떻게 보조적으로 활용할 것인지**가 핵심입니다.

기본적으로 주가 예측에서는 가격 시계열 자체가 가장 중요한 정보이며, 텍스트는 이를 보완하는 역할로 설계하는 것이 적절합니다. 따라서 모델 구조를 설계할 때 텍스트 임베딩 차원이 과도하게 커져 시계열 정보의 중요도가 희석되지 않도록 주의해야 합니다.

2. 텍스트 정보 활용에 대한 관점

텍스트가 항상 예측 성능을 개선해야 하는 것은 아닙니다. 모든 뉴스가 주가 예측에 유의미한 정보를 주는 것은 아니며, 어떤 뉴스는 도움이 되지 않거나 오히려 노이즈가 될 수 있습니다.

따라서 중요한 것은 단순히 텍스트를 넣는 것이 아니라, **어떤 텍스트가 유용한지 선별하고, 모델이 그 정보를 실제로 활용하고 있는지 검증하는 것**입니다.

특히 금융 뉴스와 SEC filing 정보는 macro, sector, related company, target company level 로 나뉘어 있으므로, 각 level 이 예측에 얼마나 기여하는지 ablation study 를 통해 확인할 필요가 있습니다.

3. 평가 지표에 대한 피드백

MSE 나 MAE 만으로 모델을 평가하는 것은 한계가 있습니다. MSE 기준으로는 실제 주가 흐름을 잘 맞추지 못하더라도, 평균값에 가깝게 평평하게 예측하는 모델이 좋은 점수를 받을 수 있습니다.

따라서 다음 지표들을 함께 확인하는 것이 필요합니다.

- MSE / MAE
- Directional Accuracy (강조하심)
- 실제값과 예측값의 plot 비교
- 가상 포트폴리오 구성 시 수익률
- 종목별, 기간별 성능 차이

특히 예측 결과를 반드시 시각화해서, 모델이 실제 주가 움직임을 따라가는지 아니면 단순히 flat 한 예측을 하고 있는지 확인해야 합니다.

4. 텍스트 임베딩 관련 피드백

시계열 예측에서 중요한 것은, 시계열 모델이 기본이 되고 텍스트 정보는 추가되는 토픽이어야 합니다. 즉, 같은 파이프라인이더라도 텍스트 임베딩에 따라 값이 확 바뀐다는 것은 텍스트 정보가 과도한 영향을 미치고 있을 수 있으니, 이를 꼭 점검해야 합니다.

텍스트 임베딩은 차원이 매우 크기 때문에 그대로 사용할 경우 문제가 생길 수 있습니다. 예를 들어 4096 차원 임베딩을 여러 text level 에 붙이면 텍스트 feature 가 시계열 feature 보다 훨씬 커지게 됩니다.

이 경우 모델이 텍스트를 의미 있는 정보로 활용하기보다, 예측값을 평평하게 만드는 bias 처럼 사용할 가능성이 있습니다.

따라서 다음 전처리 또는 구조 설계를 고려해야 합니다.

- PCA 를 통한 차원 축소
- text level 별 pooling
- projection layer 사용
- embedding dimension 축소 후 fusion
- text feature 와 price feature 의 비율 조정
- text-only 영향이 과도하지 않은지 점검

5. 임베딩 모델 선택 기준

BERT 계열 임베딩은 빠르게 실험하기에는 적합하지만, 금융 문서의 세부적인 의미를 충분히 반영하기에는 한계가 있을 수 있습니다. 특히 오래된 tokenizer 나 작은 embedding model 은 SEC filing, 금융 전문 용어, 기업 이벤트의 미묘한 차이를 충분히 포착하지 못할 수 있습니다.

반면 Linq, Qwen, LGAI 등 최신 LLM 기반 임베딩은 계산 비용은 크지만, 금융 텍스트의 세부 정보를 더 잘 반영할 가능성이 있습니다.

(텍스트 정보를 사용한다는 것은 텍스트 임베딩으로부터 얻고 싶은 것이 있을텐데, 얻고자 하는 것을 얻기 위해서는 어떠한 태스크를 잘해야 하는지 설정하고, 해당

태스크에서 성능이 좋은 텍스트 임베딩을 사용하는 것을 추천합니다. (모델-태스크별 성능은 MTEB 에서 확인 가능합니다.)

따라서 실험 전략은 다음과 같이 가져가는 것이 적절합니다.

1. 빠른 baseline 확인용으로 BERT 사용
2. 본 실험에서는 최신 LLM 기반 임베딩 중심으로 진행
3. embedding model 별 성능 차이를 비교
4. 특정 embedding 에 따라 성능이 크게 달라진다면, 모델이 시계열보다 텍스트에 과도하게 의존하는지 점검

6. 시계열 모델 선택 기준

시계열 모델은 사전에 어떤 모델이 가장 좋을지 확정하기 어렵기 때문에 여러 모델을 비교해보는 것이 현실적입니다.

다만 모델 선택 시 단순히 MSE 가 낮은 모델만 고르기보다, 해당 모델이 금융 시계열의 어떤 특성을 잘 포착한다고 가정하는지 확인해야 합니다.

예를 들어 다음과 같은 관점이 필요합니다.

- fluctuation 을 잘 포착하는가
- trend 를 잘 따라가는가
- seasonality 또는 regime change 에 대응 가능한가
- 예측값이 지나치게 flat 하지 않은가
- 텍스트를 넣었을 때 실제로 합리적인 방식으로 반응하는가

7. Toy Experiment 필요성

모델 구조가 텍스트 정보를 제대로 활용하는지 확인하기 위해 toy experiment 를 해볼 필요가 있습니다.

예를 들어 다음과 같은 실험이 가능합니다.

- 정답에 가까운 텍스트 힌트를 넣었을 때 모델 성능이 실제로 좋아지는지 확인
- 상승/하락과 관련된 텍스트만 선별해서 넣었을 때 directional accuracy 가 개선되는지 확인
- 무의미한 텍스트 또는 shuffle 된 텍스트를 넣었을 때 성능이 떨어지는지 확인

- 특정 text level 을 제거했을 때 성능 변화 확인
- 텍스트 정보가 강할수록 예측 변화도 커지는지 확인

이러한 실험은 최종 예측 성능을 위한 실험이라기보다, **모델 구조가 텍스트 정보를 제대로 받아들이는지 검증하는 실험**입니다.

8. 결과 해석 시 중요한 기준

최종적으로 중요한 것은 단순히 리더보드 점수나 MSE 가 아니라, 모델이 현실적으로 사용 가능한 방식으로 예측하고 있는지입니다.

금융 현업 관점에서는 숫자 성능이 가장 좋은 모델보다, 예측 논리가 명확하고 결과가 해석 가능한 모델이 더 중요할 수 있습니다.

따라서 결과를 정리할 때는 다음 질문에 답할 수 있어야 합니다.

- 왜 이 모델 구조를 선택했는가?
- 텍스트 정보는 실제로 성능 개선에 기여했는가?
- 어떤 text level 이 가장 유용했는가?
- 텍스트를 넣었을 때 예측이 더 합리적으로 변했는가?
- 모델이 단순히 평균값을 예측하는 방향으로 수렴하지는 않았는가?
- 성능 개선이 특정 종목이나 특정 기간에만 나타나는 것은 아닌가?
- 실제 투자 관점에서 이 예측을 사용할 수 있는가?

9. 정리

이번 미팅의 핵심은 다음과 같습니다.

시계열을 중심에 두고, 텍스트는 보조 정보로 적절히 활용해야 한다.

MSE/MAE 만 보지 말고 방향성, plot, 포트폴리오 관점의 평가를 함께 봐야 한다.

텍스트 임베딩은 차원이 크기 때문에 반드시 축소·정규화·구조적 제어가 필요하다.

모델이 텍스트를 실제로 이해하고 반영하는지 toy experiment 와 ablation 으로 검증해야 한다.

최종 결과는 숫자 성능뿐 아니라 왜 그런 구조를 선택했는지에 대한 논리까지 함께 제시해야 한다.