



LG

AI Research Task

Team 1: 이건일, 여준호, 박수빈, 신지원, 황수민

Team 2: 권나연, 이은민, 백가은, 윤동영, 이세원

Contents

01

Methodology

02

Results

03

Conclusion

Feedback & Baseline

- 시계열 모델이 중심, 텍스트는 보조 정보로 적절히 활용
- MSE/MAE만 보는 것이 아닌 **방향성 관점**으로 평가
- 텍스트 임베딩은 차원이 크기 때문에 반드시 **축소·정규화·구조적 제어** 필요
- 수치적 성능에만 집중하는 것이 아닌, **트레이더의 의사 결정 과정**을 반영한 논리 필요
- **Baseline:** 테스트 기간의 모든 샘플에 대해 **20일 후 가격 상승(up)**으로 예측
- 결과: **0.559**




01

Methodology



Team 1

Cross-attention fusion



Late fusion

가격 모델 예측값 + 텍스트 예측값을 마지막에 섞음

Cross-attention fusion

가격 시계열에서 만든 hidden state가 Query가 되고,
텍스트 category embedding이 Key/Value가 되어
예측에 필요한 텍스트 정보를 attention으로 가져옴

- **Key/ Value = Text tokens**
- **Query = Price hidden states**

Cross attention fusion

PatchTST 시계열 모델에서 Linq 텍스트는 어떻게 활용하는 것이 효과적인가?

결과:

Fusion	Direction Accuracy	Direction Loss	Close MAE
No text	0.5620	0.7018	0.5094
Late fusion	0.5652	0.6954	0.6007
Cross-attention	0.5719	0.6831	0.5333

- 1) Linq 텍스트 사용시 no text 대비 방향성 정확도 개선됨
- 2) Late fusion보다 cross-attention이 더 높은 Direction accuracy 달성

Text Level 분석

PatchTST 시계열 모델에서 어떤 Level의 텍스트가 방향성 예측에 가장 기여를 할 것인가?


Text Level	Direction Accuracy	Direction Loss	Close MAE
Target Company	0.5677	0.4281	0.4860
Filing	0.5592	0.6032	0.6035
Related Company	0.5516	0.5035	0.5241
Macro	0.5358	0.4214	0.4783
Sector	0.5244	0.5062	0.5196

- targetCompany only가 text level 단독 실험 중 Direction Accuracy 가장 높음
- all-level cross-attention 0.5719와도 거의 근접함
- > 따라서 PatchTST에서는 종목 직접 관련한 텍스트가 방향성 예측에 가장 중요

Text Level 분석

PatchTST 시계열 모델에서 어떤 Level의 텍스트가 방향성 예측에 가장 기여를 할 것인가?

PatchTST Text-Level Ablation with Linq Embeddings



PatchTST + Linq + Cross-Attention + Directional Loss | close-only, horizon_len=20
Key takeaway: targetCompany gives the best direction signal, while macro gives the lowest price error.

TimeMixer




Figure 1: Overall architecture of TimeMixer, which consists of Past-Decomposable Mixing and Future-Multipredictor-Mixing for past observations and future predictions respectively.

TimeMixer?

Transformer/Attention 없이
Linear·MLP만으로 구성된 시계열
예측 아키텍처. 같은 시계열도
관찰하는 시간 해상도(scale)에
따라 다른 패턴이 드러난다는
관점에서 출발

핵심 원리

- 256~32일 다중 스케일 동시 생성
→ 같은 구간을 여러 배율로 관찰
- season(fine → coarse) ·
trend(coarse → fine) 양방향 mixing
- 스케일별 예측 앙상블해 서로 다른
해상도의 예측력 보완

Why TimeMixer?

- season/trend 분해가 그대로 해석
가능한 진단값 제공 → 예측 근거 설명
가능
- 스케일 구조가 텍스트 정보를 시간
축에 맞게 붙일 자리 제공

TimeMixerFusion (0.522)

PDM 이후 텍스트 주입하는 late-fusion 확장

Scale 0 · T=256 (원본)
Surprise (additive)

Scale 1 · T=128 (2일씩 압축)
주입 X

Scale 2 · T=64 (4일씩 압축)
Sector (additive)

Scale 3 · T=32 (8일씩 압축)
Macro (FiLM)



Direction Head

각 Scale: mean-pool(T) → Linear(d_model → 1) → per-scale logit → softmax 학습 가중치로 합산(backbone logit)
→ + FilingNewsHead(filing + lseg) 보정 → direction logit → P(up)=sigmoid → up/down (threshold 0.5)

구조 변경

기존 FMM(가격 예측 전용) → Direction Head

- PDM 이후 텍스트 주입: 가격 신호와 텍스트 보정을 분리해 attribution

- 스케일마다 다른 텍스트: 각 정보의 갱신 주기가 다르기 때문에 스케일을 맞추기 위함

텍스트 주입 위치


- Scale 0 = surprise(additive)
- Scale 2 = sector(additive)
- Scale 3 = macro(FiLM/gate)

- Scale 무관 = filing + lseg
→ 최종 logit 보정


실험 결과

Direction Accuracy: 0.522

TimeMixerFusion



TimeMixerFusion



Higher bar = removing that text path hurts accuracy more → stronger contribution to direction prediction.

각 텍스트 모듈을 하나씩 제거했을 때 direction accuracy가 얼마나 떨어지는지를 기준으로
기여도 측정

Surprise > Macro > Sector 순으로 방향 예측에 기여

DoubleAdapt

하나의 롤링 태스크 (support→query) 안에서 Data Adapter + Model Adapter가 이중으로 변형



시스템 동작 모드 제어

2019 - 2021 | 27개 롤링 태스크

위 루프 전체가 완전히 활성화, 역전파를 통해 θ 가 실제로 실시간 업데이트
(train.parquet 범위 내에서만 정밀 학습 수행)

2022 - 2023 | 11개 롤링 태스크

outer-loop 역전파 루프가 완전히 차단 (freeze_online=1).
 θ 가중치가 고정된 상태로 순방향 추론 (Forward Pass)만 안정적으로 수행

DoubleAdapt

Core Mechanism

K-of-N Loss Function Adjustment

1. Text embedding 6종 개별 투표

2. 6개 중 4개 이상 동의
`novelty_consensus = 1`

3. `News_weight_mult = 10`
해당 샘플 loss를 10배 가중

macro_category1~5	5	텍스트 ID → linq 임베딩 조회 → 5개 평균 → PCA 6차원	macro_pc0~5 (6개)
sector_category1~5	5	위와 동일 방식	sector_pc0~5 (6개)
relatedCompany_category1~3	3	위와 동일 방식 + 6개 모델 컨센서스로 novelty 3개 별도 산출	related_pc0~5 (6개) + related novelty 3개
targetCompany_category1~3 + filing_financialStatement/governanceRisks ...	3+5=8	위와 동일 방식 + 컨센서스 novelty 3개	target_pc0~5 (6개) + target novelty 3개

Idea)

- 텍스트 신호 최대 활용(신호가 미미한 target/related level에 도입) 및 중요 구간 집중 학습
- 6개 임베딩 모두를 활용하여 단일 임베딩 노이즈 최소화

투표 방식)

(6개 모델: linq/bert/gemini/lgai/nvda/qwen)

1. 모델별로 각 종목의 텍스트 임베딩에 대해 최근 20일 롤링 평균을 계산
2. 오늘 임베딩과 롤링 평균 사이 코사인 거리 측정
3. 훈련 기간 분포 기준 상위 10%(quantile=0.9)만큼 거리가 크면 그 모델은 "새롭다"고 투표
4. 6개 중 4개 이상(2/3) 동의하면 최종 novelty=1 확정

Linq

Embedding	Method	Direction Accuracy
Linq	Always Up (Baseline)	0.5588
	D.A + iTransformer	0.4765
	D.A + PatchTST	0.4983
	D.A+TimesNet	0.5249
	D.A + GRU	0.5265
	D.A + DLinear	0.5495
	D.A + DLinear, reg=1.0, news_weight_mult=10	0.5740
	D.A + DLinear, reg=1.0, news_weight_mult=10 (freeze_online)	0.5900



submission_dlinear_newsweigh...
Complete · 3h ago

0.56854




submission_dlinear_final_compli...
Complete · 2h ago

0.54738




Team 2

임베딩 정보량 검증 - Oracle 주입 실험



병목은 아키텍처가 아니라 임베딩의 정보량

임베딩 공간 상승/하락 분리도 분석




색상 = 20일 후 수익률 방향 (빨강: 상승, 파랑: 하락)

$sep_ratio = \text{상승/하락 중심점 간 거리} \div \text{전체 분산}$
1이면 완전 분리, 0이면 무작위

레벨 조합	sep_ratio
targetCompany	0.034
+related+sector	0.037
6레벨 전체	0.057
targetCompany (누적평균)	0.038
+related+sector (누적평균)	0.040
6레벨 전체 (누적평균)	0.033

➡ 어떤 레벨 조합, 어떤 윈도우를 써도 임베딩 공간에서 상승/하락은 구분되지 않는다.

Text는 모든 종목, 시점에 똑같이 기여하는가?



Metric

RDA = Relative Direction Accuracy

※ 랜덤 기준선 = 0.500

출력 $s(i,t)$ 는 rank loss로 학습된 '순위 점수' → 단위가 없고, 부호 자체에는 의미가 없음. 기준선이 필요함
종목 i 의 점수가 '그 종목의 평소 수준(평균)'보다 높은 날에, 실제로도 20일 수익이 양수였던 비율

즉, "이 종목이 평소보다 텍스트 신호가 강하게 나온 날, 실제로 올랐는가?"

Text는 모든 종목, 시점에 똑같이 기여하는가?


텍스트는 어느 종목에서 기여도가 높은가?

관심 대리변수	lgai	qwen	nvda
거래량 (volume)	+0.316	+0.203	+0.225
회전율 (turnover)	+0.264	+0.164	+0.186
변동성 (volatility)	+0.288	+0.133	+0.190
통합 관심지수 (PC1)	+0.333	+0.199	+0.233

⇒ 관심도가 높은 종목일수록,
텍스트를 넣고 뺄 때 예측 차이가 크다.

PC1 분산설명 52.5% · 거래량 통제 후에도 변동성 잔존(+0.13~0.21) → 독립 2축

Text는 모든 종목, 시점에 똑같이 기여하는가?



오차막대(±std)가 모두 0을 관통 → 12개월 전부 유의하지 않음 (0/12)

양수 5 / 음수 7 · seed마다 상위월이 9·11·12월로 뒤바뀜 = 노이즈

Text는 모든 종목, 시점에 똑같이 기여하는가?

텍스트는 어느 시점에서 기여도가 높은가?

시점 축 (그날의 시장 상태)	방향(hit) 기여	순위(rank-IC) 기여	판정
변동성 높은 날	-0.012 (n.s.)	-0.018 (n.s.)	효과 없음
거래량 많은 날	-0.002 (n.s.)	-0.015 (n.s.)	효과 없음
뉴스 많은 날	+0.004 (n.s.)	+0.009 (n.s.)	효과 없음
상승장 vs 하락장	-0.027 (n.s.)	-0.046 (n.s.)	효과 없음

⇒ 시점(월·시장상태) 어느 축으로도 텍스트 기여는 유의하게 커지지 않는다
— "언제"가 아니라 "어떤 종목이냐"의 문제

Text는 모든 종목, 시점에 똑같이 기여하는가?

최적 레벨 탐색


Embedding	iTransformer 최적 레벨	PatchTST 최적 레벨
lgai	lseg (0.057)	targetCompany (0.020)
qwen	filing (0.048)	relatedCompany (0.034)
nvda	lseg (0.047)	lseg (0.032)
linq	target+related (0.048)	relatedCompany (0.024)
bert	sector (0.036)	relatedCompany (0.027)
gemini	targetCompany (0.050)	lseg (0.030)

⇒ 최적 레벨은 임베딩과 인코더의 함수
→ Encoder × Embedding × Level 3중 상호작용

Text는 모든 종목, 시점에 똑같이 기여하는가?

종목별 최적레벨


Embedding	집계 (전체평균)	Oracle 간극 도달률	레벨 일치율
gemini	0.5015	80%	52%
qwen	0.5012	85%	56%
lgai	0.5025	81%	56%




⇒ 종목마다 반응하는 텍스트 레벨이 다르다.

Text는 모든 종목, 시점에 똑같이 기여하는가?

선별은 어디에서 효과적인가?



관심이 높을수록 선별이 더 잘 통한다 — 3임베딩 일관



관심 하위 종목의 텍스트를 끈 비율

⇒ 저관심 = 텍스트가 노이즈로 더 크게 작용.
0.5322 → 0.5416 (+0.0094) 3개 임베딩 전부 단조 상승

Why These Metrics?

- flat하게 예측하는 모델도 MSE 기준으로는 좋은 점수를 받을 수 있음
- 실제 투자 관점에서는 "얼마나 정확하냐"보다 **"방향을 맞추느냐", "종목 간 순위를 맞추느냐"**가 더 중요


Category	Metrics	Description
정확도	MSE, MAE	예측값이 실제값에서 얼마나 벗어났는지
방향성	Directional Accuracy, F1	오를지 내릴지 방향을 맞추는 비율
랭킹	IC, Rank IC, ICIR	종목 간 수익률 순위를 얼마나 잘 맞추는지
포트폴리오	Sharpe, MDD, Turnover	실전 투자 관점에서 이 예측을 쓸 수 있는지

Why These Metrics?


Metric	가격	가격 + 텍스트	shuffle
MSE	0.249	0.198	0.247
Directional ACC	54.2%	61.8%	53.9%
IC	0.038	0.09	0.036
ICIR	0.48	1.15	0.45
Sharpe Ratio	0.31	1.24	-
Max Drawdown	-9.7%	-4.1%	-

예측값의 변화

: 정상시계열로의 변화



(오늘 증가 - 어제 증가)
/ 어제 증가



예측값의 변화

: 정상시계열로의 변화

정규화	지표
z-mse	0.2244
Hit rate	0.5159
Direction acc	0.5158
Rank IC	0.9956

→
(오늘 증가 - 어제 증가)
/ 어제 증가

변화율화	지표
z-mse	0.2297
Hit rate	0.5521
Direction acc	0.5520
Rank IC	0.9956

순서 맞춰서 정리중
(여기까지)

Team 2

New Metric: Direction Accuracy

: 20일 후 주가 방향을 맞췄는가?

20일 후 종가가 오를 것이라 예측했을 때 실제로도 올랐는지,
내릴 것이라 예측했을 때 실제로도 내렸는지를 맞춘 비율

$$\begin{aligned} &\text{sign}(\text{pred_close}[t+20] - \text{close}[t]) \\ &== \\ &\text{sign}(\text{actual_close}[t+20] - \text{close}[t]) \end{aligned}$$

Always up: 0.5588

TS_query_sparse

: 현재 TS 흐름에 따라 참고할 text level을 선택

뉴스의 중요도는 시장 상황에 따라 달라짐!

시장 전체가 금리나 물가에 민감하다면
특정 섹터가 강하게 움직이는 구간이라면
개별 기업 이벤트가 주가를 움직이는 구간이라면




Macro
Sector
targetCompany, filing

가격 흐름 요약 **q_ts**와 text level representation **h_1**을 보고
top-k level만 선택, residual correction에 반영

TS_query_sparse

: 현재 TS 흐름에 따라 참고할 text level을 선택




Idea: let the current time-series state decide which text levels should provide a small residual correction.

Model	Accuracy
Always up	0.5588
TS_query_sparse	0.5492

TS_flow_router


: 지금 TS 흐름에서 어떤 **text level**이 실제 미래 방향 보정에 유용한가?



TS_flow_router

: 지금 TS 흐름에서 어떤 text level이 실제 미래 방향 보정에 유용한가?

TS-flow routing with direction-aware utility supervision



Idea: route text using the current TS flow, and supervise the router toward levels that are more useful for future direction-aware residual correction.

Model	Accuracy
Always up	0.5588
TS_query_sparse	0.5492
TS_flow_router	0.5498

Why These Metrics?

- 평균값에 가깝게 flat하게 예측하는 모델도 MSE 기준으로는 좋은 점수를 받을 수 있음
- 실제 투자 관점에서는 "얼마나 정확하냐"보다 **"방향을 맞추느냐", "종목 간 순위를 맞추느냐"**가 더 중요

Category	Metrics	Description
정확도	MSE, MAE	예측값이 실제값에서 얼마나 벗어났는지
방향성	Directional Accuracy, F1	오를지 내릴지 방향을 맞추는 비율
랭킹	IC, Rank IC, ICIR	종목 간 수익률 순위를 얼마나 잘 맞추는지
포트폴리오	Sharpe, MDD, Turnover	실전 투자 관점에서 이 예측을 쓸 수 있는지

Why These Metrics?

Metric	가격	가격 + 텍스트	shuffle
MSE	0.249	0.198	0.247
Directional ACC	54.2%	61.8%	53.9%
IC	0.038	0.09	0.036
ICIR	0.48	1.15	0.45
Sharpe Ratio	0.31	1.24	-
Max Drawdown	-9.7%	-4.1%	-


Metric 구성

Directional ACC	일반적으로는 단순히 상승/하락 2분류로 방향을 맞춘 비율을 보지만, 우리 태스크에서는 0 근처 움직임은 노이즈가 많다는 점을 반영해 direction_3class (positive / neutral / negative)로 수정
IC	내 모델이 예측한 종목 순위가 실제 수익률 순위와 얼마나 일치하는지. 절대적인 예측 오차보다 "어떤 종목이 더 오를지"를 맞추는 능력을 측정. 0.05 이상이면 의미 있는 신호로 간주
Rank IC	IC의 극단적인 이상치 영향을 줄여 더 안정적인 측정 가능
ICIR	가끔 잘 맞추는 모델과 꾸준히 잘 맞추는 모델을 구분하는 지표. 1.0 이상이면 안정적인 알파로 평가
* Sharpe Ratio	얼마나 벌었는지와 얼마나 안정적으로 벌었는지를 동시에 측정. 1 이상이면 현업 기준 "쓸 만한 전략"
* Max Drawdown	투자 기간 중 최고점 대비 가장 많이 떨어진 폭. 실제 투자자가 버틸 수 있는 전략인지 확인

* 부분은 퀀트 현업에서 포트폴리오 관점에서 사용하는 지표들을 태스크에 맞게 재구성한 metric


이기는 성능은 없었어서 그냥 성능 표는 뺐어욤

임베딩 정보량 검증 - Oracle 주입 실험



병목은 아키텍처가 아니라 임베딩의 정보량

임베딩 공간 상승/하락 분리도 분석



색상 = 20일 후 수익률 방향 (빨강: 상승, 파랑: 하락)

$\text{sep_ratio} = \text{상승/하락 중심점 간 거리} \div \text{전체 분산}$
1이면 완전 분리, 0이면 무작위


레벨 조합	sep_ratio
targetCompany	0.034
+related+sector	0.037
6레벨 전체	0.057
targetCompany (누적평균)	0.038
+related+sector (누적평균)	0.040
6레벨 전체 (누적평균)	0.033




어떤 레벨 조합, 어떤 윈도우를 써도 임베딩 공간에서
상승/하락은 구분되지 않는다.

예측값의 변화

: 정상시계열로의 변화



(오늘 증가 - 어제 증가)
/ 어제 증가



예측값의 변화

: 정상시계열로의 변화

Chronos (context:1024)

정규화	지표
z-mse	0.2244
Hit rate	0.5159
Direction acc	0.5158
Rank IC	0.9956



(오늘 증가 - 어제 증가)
/ 어제 증가

변화율화	지표
z-mse	0.2297
Hit rate	0.5521
Direction acc	0.5520
Rank IC	0.9956

백가은 내용

이 챗터는 뉴스 텍스트가 모든 종목과 모든 시점에 똑같이 기여하는지를 알기 위해 실험의 결과입니다. 가설은 시장의 관심이 높은 종목일수록, 뉴스가 가격에 빠르게 반영되고, 그래서 그 종목 예측에 텍스트가 더 크게 기여한다. 이 화살표들을 하나씩 데이터로 검증했습니다.

측정 지표부터 짚겠습니다. 저희 지표는 RDA, 상대 방향 정확도입니다. 모델이 내는 점수는 순위 점수라 부호 자체엔 의미가 없어서, 그 종목의 평소 평균을 기준으로 삼습니다. '이 종목이 평소보다 신호가 강한 날, 실제로 올랐나'를 봅니다. 무작위로 찍으면 정확히 0.5가 나오는 지표입니다.


첫 번째 발견입니다. 텍스트를 넣었을 때와 뒤섞었을 때의 예측 차이, 즉 텍스트 기여도를 종목마다 재봤습니다. 그걸 그 종목의 거래량·변동성과 상관을 냈더니 전부 양의 상관, Igai에서 0.3 안팎이 나옵니다.

맨 아래 통합 관심지수가 개별 변수보다 상관이 높습니다. 관심도가 높은 종목에 텍스트의 기여도가 높습니다.

다음으로는 종목이 아니라 특정 '시점'에서의 텍스트 기여도를 알기 위해서 먼저 달력 월로 봤습니다.

이 그래프에서 중요한 건 막대 높이가 아니라 오차막대입니다. 열두 달 전부 오차막대가 0을 관통합니다. 5 seed로 검정하면 12개월 전부 유의하지 않았습니다. 예비 실험에선 6월, 11월이 간헐적으로 seed를 늘려도 사라집니다.

Text는 모든 종목, 시점에 똑같이 기여하는가?



Metric

RDA = Relative Direction Accuracy

※ 랜덤 기준선 = 0.500

출력 $s(i,t)$ 는 rank loss로 학습된 '순위 점수' → 단위가 없고, 부호 자체에는 의미가 없음. 기준선이 필요함
종목 i 의 점수가 '그 종목의 평소 수준(평균)'보다 높은 날에, 실제로도 20일 수익이 양수였던 비율

즉, "이 종목이 평소보다 텍스트 신호가 강하게 나온 날, 실제로 올랐는가?"

Text는 모든 종목, 시점에 똑같이 기여하는가?


텍스트는 어느 종목에서 기여도가 높은가?

관심 대리변수	lgai	qwen	nvda
거래량 (volume)	+0.316	+0.203	+0.225
회전율 (turnover)	+0.264	+0.164	+0.186
변동성 (volatility)	+0.288	+0.133	+0.190
통합 관심지수 (PC1)	+0.333	+0.199	+0.233

⇒ 관심도가 높은 종목일수록,
텍스트를 넣고 뺄 때 예측 차이가 크다.

PC1 분산설명 52.5% · 거래량 통제 후에도 변동성 잔존(+0.13~0.21) → 독립 2축

Text는 모든 종목, 시점에 똑같이 기여하는가?



오차막대(±std)가 모두 0을 관통 → 12개월 전부 유의하지 않음 (0/12)

양수 5 / 음수 7 · seed마다 상위월이 9·11·12월로 뒤바뀜 = 노이즈

Text는 모든 종목, 시점에 똑같이 기여하는가?

텍스트는 어느 시점에서 기여도가 높은가?

시점 축 (그날의 시장 상태)	방향(hit) 기여	순위(rank-IC) 기여	판정
변동성 높은 날	-0.012 (n.s.)	-0.018 (n.s.)	효과 없음
거래량 많은 날	-0.002 (n.s.)	-0.015 (n.s.)	효과 없음
뉴스 많은 날	+0.004 (n.s.)	+0.009 (n.s.)	효과 없음
상승장 vs 하락장	-0.027 (n.s.)	-0.046 (n.s.)	효과 없음

⇒ 시점(월·시장상태) 어느 축으로도 텍스트 기여는 유의하게 커지지 않는다
— "언제"가 아니라 "어떤 종목이냐"의 문제

Text는 모든 종목, 시점에 똑같이 기여하는가?

최적 레벨 탐색


Embedding	iTransformer 최적 레벨	PatchTST 최적 레벨
lgai	lseg (0.057)	targetCompany (0.020)
qwen	filing (0.048)	relatedCompany (0.034)
nvda	lseg (0.047)	lseg (0.032)
linq	target+related (0.048)	relatedCompany (0.024)
bert	sector (0.036)	relatedCompany (0.027)
gemini	targetCompany (0.050)	lseg (0.030)

⇒ 최적 레벨은 임베딩과 인코더의 함수
→ Encoder × Embedding × Level 3중 상호작용

Text는 모든 종목, 시점에 똑같이 기여하는가?

종목별 최적레벨


Embedding	집계 (전체평균)	Oracle 간극 도달률	레벨 일치율
gemini	0.5015	80%	52%
qwen	0.5012	85%	56%
lgai	0.5025	81%	56%




⇒ 종목마다 반응하는 텍스트 레벨이 다르다.

Text는 모든 종목, 시점에 똑같이 기여하는가?

선별은 어디에서 효과적인가?



관심이 높을수록 선별이 더 잘 통한다 — 3임베딩 일관



관심 하위 종목의 텍스트를 끈 비율

⇒ 저관심 = 텍스트가 노이즈로 더 크게 작용.
0.5322 → 0.5416 (+0.0094) 3개 임베딩 전부 단조 상승



02

Conclusion

아래 형식과 유사하게 전체 결과 업데이트 필요

Method(best score)	Text Embedding	Backbone	Test Direction Accuracy
Cross Attention	Linq	PatchTST	0.572
TimeMixerFusion	Linq	TimeMixer	
Double Adapt	Linq	Dlinear	
TS Flow Router		PatchTST	0.550

Conclusion 업데이트

1. Text is not always helpful

: 텍스트 임베딩은 추가 정보가 될 수 있지만
관련성이 낮거나 예측 시점에 유효하지 않은 정보는 쉽게 노이즈로 작용

..

2. Selective level usage matters

: 모든 텍스트 레벨을 일괄적으로 사용하는 것보다
일부 중요한 레벨을 선택하거나 level별 가중치를 조정하여 활용하는 방식이 더 효과적
4주 horizon에서는 개별 기업 뉴스보다 매크로/섹터 공통 요인이 더 강한 신호로 작용

..

3. Complex fusion easily overfits

: 텍스트 임베딩의 높은 차원과 level별 노이즈 차이로 인해
복잡한 모델 구조는 성능 향상보다 과적합을 유발할 가능성 높음

..

4. Future direction

: 임베딩 모델에 따라 중요하게 작용하는 텍스트 level이 달라질 가능성 존재





03

Conclusion

Conclusion


- **Backbone** 선택이 **fusion** 방식보다 더 중요한 변수
PatchTST가 DLinear를 전반적으로 압도.
DLinear는 복잡한 fusion 로직과 궁합이 좋지 않음. 단순 late fusion이나 text-to-signal에서만 경쟁력 있음.
- **Best 조합: BERT + PatchTST + By-text-level(macro), MSE 0.210**
text level 선택이 단순 mean pooling 대비 유의미한 개선을 이끌어냄.
4주 horizon에서는 개별 기업 뉴스보다 매크로/섹터 공통 요인이 더 강한 신호로 작용.
- **Fusion 방식별 Summary**
By-text-level이 가장 안정적이고 전반적으로 우수.
Surprise method의 경우 BERT+PatchTST에서 소폭 개선.
Text-to-Signal은 Linq에서 경량 대비 성능 효율 확인.
Cross Attention은 Linq + Transformer 계열 backbone 조합에서 유망

The background features abstract, flowing wavy lines in shades of blue and teal. In the bottom right corner, there is a network diagram consisting of small blue dots connected by thin, light blue lines, forming a complex web-like structure.


Thanks!

CREDITS: This presentation template was created by [Slidesgo](#), and includes icons by [Flaticon](#), and infographics & images by [Freepik](#)

Bradley-Terry Model Prediction (0.574)



Prediction Result - AAPL



Prediction Result - ACN

