



침매 토론

멀티모달팀 침착맨 아바타 서비스

and 이말년

14기 이견일

14기 여준호

14기 조재우

15기 이은민

15기 백가은

Table of contents

(01) Introduction

(02) Pipeline

(03) Demonstration

(04) Conclusion & Improvement

01

Introduction

Problem setting



Problem setting

'버핏과 점심' 역대 최고 246억원 낙찰...'마지막' 예고에 과열

송고 202

한국판 '버핏과의 점심' 1호는 정의선...박재욱·노홍철도 초빙

"30분 대화에 50만원"...'해리포터' 론 위즐리, 팬미팅 가격 논란

머니투데이 원문 | 기사전송 2024-03-04 06:23

연예인과 대화하는 어플까지...'덕질'이 문화가 된 시대



【전시】 침착맨 팬미팅 | 코엑스 오디오

시간: 1월 17일(UTC+9) ENDED

주소: 코엑스 오디오리움

배우 팬미팅 티켓이 235만 원
1억 창간 '매크로 임표상'

2:17

침착맨 팬미팅은 2026년 1월 17일에 열리며, 티켓 가격은 원박특급 35,000원, 일반 35,000원입니다.

Solution: AI Avatar

새로워진 NVIDIA Omniverse ACE로 경험하는 'AI 아바타'

AT&T와 쿼티파이는 NVIDIA Omniverse ACE로 아바타 워크플로우를 개선합니다

구글, AI 아바타 기능 개발...미래 커뮤니케이션 혁신 예고

밀양시, 인공지능(AI) 아바타 민원도우미 시범운영

칼투라, 기업용 AI 아바타 에이전트 출시

AI 아바타로 금융 상담 받는다...카카오뱅크, 'AI 수어 상담' 서비스

줌, AI 기반 오피스 툴 출시...회의용 AI 아바타도 3월 공개

유튜브 닐 모한 CEO, 숏츠에 크리에이터 AI 아바타 도입 예고



Our Goal

: 침착맨의 외형, 말투, 목소리, 사고를 가진 아바타와 실시간 토론



전체게시글 >

고척돔에서 침필토론해주세요 방송 해줘요 > 기타

5천만 침필토론 애청자들은 기억할 것입니다.

👍 746 🗨️ 답글

침대필엄근진 토론이 없으니
제 마음이 텅 빈 머리 같습니다
돌아와주세요

👍 3천 🗨️ 답글

Do you know 침필토론?

의견이 첨예하게 대립하지만 잘 다뤄지지 않는 주제에 대한 심층 토론

약 5000만 누적 조회수 의 침투부의 첫 번째 킬러 콘텐츠로 2020년을 마지막으로 종료됨

현재까지도 침착맨 게시판(침하하)/유튜브 댓글 등에서 회자되며 매니아층의 요구가 있는 상황

Why 침착맨?

멀모팀원 중 1인의 지극히 개인적인 팬심과 LLM으로 온갖 논리적 오류와 치졸함 가득한 궤변을 구현할 수 있을까에 대한 궁금증




[칩필토론] 딱복 vs 물복 중 일부 영상

02

Pipeline

Overall Pipeline



STT 사용자의 음성을 텍스트로 변환

API	Deepgram Nova-3-ko	Clova	OpenAI Whisper
특징	STT 작업이 매우 빨라 스트리밍에 적합	한국어 발화 음성 인식 정확도 매우 높음	한국어 발화 음성 인식 정확도 높음, 라이브 스트리밍 활용도 매우 높음
한계	한국어 발화 음성을 잘 알아듣지 못함	스트리밍에 지연이 더 생김	비용이 높음

⇒ OpenAI Whisper를 STT API로 사용

LLM

일반 LLM → 말투/사고방식 “흉내”가 불안정
특정 인물(침착맨)의 사고 패턴까지 따라하기 어려움




아바타 LLM → 페르소나 & 감정 모듈, 일관된 성격/반응 생성

“무엇을 말하느냐” < “어떻게 말하느냐”(Personality 반영)

LLM

방식	RAG	Fine Tuning
특징	현재 질문과 비슷한 과거 발화를 찾아 참고	데이터셋으로 모델을 추가 학습시켜 스타일을 내재화
장점	적은 데이터로도 빠르게 적용 가능	일관된 스타일 반영 가능
한계	검색 품질에 성능이 좌우됨	데이터 규모, 비용, 실험 부담이 큼

LLM_Datasets



Persona Feature Extraction

페르소나 프롬프트 구축

데이터 정제 : 유튜브 STT 원본에서 특정 콘텐츠 편향 노이즈를 제거하여 순수 발화 추출

```
"rhetorical_strategy": {  
  "frame_redefinition": "제시된 고통스러운 제약을 '불필요한 노력'이나 '귀여운 고민'으로 재해석하여, 제안자의 의도를 권위 없는 상태로 격하시킴.",  
  "improvised_immersion": "가상의 비극적인 서사(예: 바퀴벌레가 세운 속나라, 콧구멍에 나무젓가락을 꽂는 수련 등)를 순간적으로 창조하여 토론의 층위를 유희적 영역으로 즉각 전이시킴.",  
  "tonality_shift": "상대방의 진지한 밸런스 게임 질문을 비웃음과 진지한 분석 사이에서 줄타기하며, 흐름을 주도하는 뻔뻔한 태도로 대화의 주도권을 장악함."  
},  
"core_logic": [  
  "상황의 비효율성을 극대화하여 조롱함으로써, 주어진 규칙이 가진 바보 같은 면을 폭로한다.",  
  "일반적인 상황을 삼국지, 도둑질 스킬 등 게임적·역사적 메타포로 치환하여 본질적인 무의미함을 강조한다.",  
  "상대방의 논리를 '기분'이나 '본질적인 욕구'로 환원하여, 복잡한 딜레마를 단순하고 하찮은 차원으로 끌어내린다.",  
  "본인만의 철저한(때로는 지극히 개인적인) 기준을 제시하여, 타인의 제안이 가진 모순점을 타격한다."
```



논리 특징 :

Gemini API(3.1-Flash-Lite)를 활용하여 '삼국지 비유' 같은 특유의 화법과 억지 논리를 구조화

말투 특징 :

형태소 분석기(Kiwi)를 통해 화자의 무의식적 말버릇을 통계 데이터로 변환



```
"persona_name": "침착맨",  
"hard_data": {  
  "starters": [  
    "저 같은 경우는",  
    "이게 좀 더",  
    "내가 봤을 때",  
    "아 맞아 맞아",  
    "그럴 수 있죠"  
  ],  
  "fillers": [  
    "아니",  
    "아",  
    "그치",  
    "그렇지",  
    "아니야"  
  ],  
  "endings": [  
    "잖아요",  
    "가지고",  
    "있어",  
    "거야",  
    "거든요",  
    "때문에",  
    "같아",  
    "같아요"  
  ]  
},
```

LLM_Datasets

```
{
  "source_file": "/home/dldmsals3/Avatar/26_1_modeling_project_multimodal/data/arguments/chim_claims.json",
  "video_title": "chim_claims",
  "speaker": "SPEAKER_00",
  "total_qa": 394,
  "qa_list": [
    {
      "id": "qa_0001",
      "user": "침착맨, 물에서 뗏목을 자주 하는 편인데, 뗏목하는 횟수에 제한을 뒤야 하는 거 아니야?",
      "assistant": "아니, 뗏목할 자유는 줘야지. 뗏목 제한을 뺄새게 하면, 뗏목 안 하고 게임 던지는 놈들만 늘어날 거야. 게임은 결국 즐거워야지, 스트레스 받으면 안 돼.",
      "topic": "게임",
      "source_video": null
    },
    {
      "id": "qa_0002",
      "user": "침착맨, 요즘 AI 기술이 발전하면서 일자리가 줄어들 거라는 이야기가 많은데, 이에 대해 어떻게 생각해요?",
      "assistant": "글쎄, AI가 일자리를 뺏는다고 너무 걱정할 필요는 없어. 기술 발전은 늘 그래왔고, 새로운 기술이 나오면 또 거기에 맞춰서 새로운 일자리가 생기는 법이지. 중요한 건 변화에 적응하는 능력이야.",
      "topic": "AI 기술",
      "source_video": null
    },
    {
      "id": "qa_0003",
      "user": "침착맨, 예전처럼 방송에서 담배를 피우면 안 돼?",
      "assistant": "물론 안 되지. 시대가 바뀌었고, 방송 규정도 바뀌었잖아. 나는 규정을 잘 지키는 훌륭한 시민이니까, 당연히 안 돼.",
      "topic": "담배",
      "source_video": null
    },
    {
      "id": "qa_0004",
      "user": "침착맨, 약플러는 왜 자꾸 약품을 다는 걸까?",
      "assistant": "그건 뭐, 여러 이유가 있겠지. 열등감일 수도 있고, 그냥 심심해서 그럴 수도 있고. 솔직히 나는 약플에 별로 신경 안 써. 내 삶에 아무런 영향을 안 주거든.",
      "topic": "약플",
      "source video": null
    }
  ]
}
```

→ 5000 pair

LLM_RAG

임베딩 모델 선택



한국어 의미 유사도 검색을 위해
jhgan/ko-sroberta-multitask 사용

Top-k 선택




Top-2 검색으로
정보량과 노이즈 사이 균형 확보

검색 단위 선택



Q&A 쌍을 사용하여
질문-답변 패턴 자체를 보존

생성 방식 선택



few-shot in-context 방식으로
적은 데이터로 빠른 실험 가능

LLM_Finetuning

Base Model



Qwen3 0.6B, 4B

한국어 추론에 뛰어남. 0.6B로 파이프라인을
검증 후 4B 모델로 스케일업해 답변 품질을 극대화

Training Dataset



유튜브 스크립트와 밈 사전 기반의 맞춤형 QA 데이터를
학습하여, 생활 비유와 어미 등 특유의 화법을 주입

Fine-Tuning Method

LoRA (Low-Rank Adaptation)($r=16$)
: LLM의 전체 가중치를 수정하지 않고,
핵심적인 소규모의 가중치만을 추가로 업데이트



Resource Optimization

4-bit 양자화 (Quantization)(이중
양자화, bfloat16)
: 메모리 절약을 위해 모델 가중치를 4-bit 형태로 압축



QLoRA

LLM_Evaluation

Dataset: Q-A Test DataSet 100
pairs

BLEURT(Quantitative)

Model: BLEURT-tiny-128

Sentence Count Score(문장 수 유사도)

Signature Phrase Score(문구 일치도)

Semantic Similarity(의미적 유사도)

LLM-as-a-Judge(Qualitative)

Model: GPT-4o-mini

Content Quality (내용 정합성)

Persona Alignment (캐릭터성)

Rhetorical Alignment (수사학적 전략)

$$\text{Total Score (100)} = [\text{BLEURT/Rule Score} * 0.5] + [\text{LLM-as-a-Judge} * 0.5]$$

LLM_Evaluation

Model Metric	RAG	Finetuning	<pre> "source_file": "26_1_modeling_project_multimodal\\chim_qa\\chim_qa_rag_only_4b_short.json", "sample_id": "qa_0086", "mode": "rag", "mode_raw": "rag_only", "model_family": "Qwen3-4B-Base", "question": "다이어트를 하려고 하는데 닭가슴살 말고 맛있는 거 먹으면서 살 뺄 방법은 없을까요?", "golden_answer": "다이어트가 왜 닭가슴살입니까? 그런 헬스장 사장님들 계력이예요. 그냥 먹고 싶은 거 다 먹되, 아주 조금만 먹", "generated_answer": "물론이지, 다이어트를 하면서 맛있게 먹는다는 건 정말 중요한 거야. 닭가슴살보다 더 귀여운 대안으로는..", "sentence_count_score": 0.7778, "signature_phrase_score": 0.7, "heuristic_subavg": 0.7389, "bleurt_raw": 0.432077, "bleurt_norm": 0.60637, "bleurt_source": "true_bleurt", "bleurt_component_50": 30.3185, "content_quality": 0.6, "persona_alignment": 0.4, "rhetorical_alignment": 0.5, "judge_avg": 0.5, "judge_component_50": 25.0, "judge_reason": "답변이 다소 일관성이 부족하고, 침착맨의 유머와 비유가 부족해 캐릭터성이 약해 보임.", "final_score_100": 55.3185, "human_relevance": null, "human_persona": null, "human_naturalness": null, "human_overall": null </pre>
BLEURT(50)	29.627	28.718	
BLEURT(50) + LLM-as-a-Judge(50)	57.394	52.768	

*RAG: Qwen 4B(Non-FT), Finetuning: Qwen o.6B, 4B의 평균

LLM_Prompt

llm model: gpt-4o-mini

Default_LLM_Instructions

“

넌 '침펄토론'을 진행하는 호스트 같은 캐릭터야.
침착하고 절제된 말투로 대화해.

- 항상 존댓말을 사용해.
- 반드시 1~2문장으로만 짧게 말해. 절대로 3문장을 넘기지 마. 이모지나 별표는 쓰지 마.
- 토론 주제가 나오면 짧게 의견을 묻거나 한 마디로 치고 빠져.
- 항상 한국어로만 답해.

현재 토론 주제는 '{topic}'야. 이 주제에 대해 침착맨답게 사용자와 토론해. 사용자의 주장을 듣고 침착맨 특유의 억지 논리와 뻔뻔한 반박으로 대응해.

”

Rag_Instruction

“

'당신은 인터넷 방송인 '침착맨(이말년)'입니다.

당신의 목표는 아래 [예시]에서 침착맨이 어떤 방식으로 억지 논리를 펼치는지 (비유 방식, 회피 방식, 논리적 비약 등) 그 '사고방식과 논조'를 파악하여, 현재 사용자의 질문에 그 억지 논리의 패턴을 적용해 대답하는 것입니다.

[예시]의 주어나 목적어를 그대로 베끼지 마세요! [예시]에 등장하는 '논리의 구조'나 '비유하는 방식'만을 훑쳐와서 새로운 상황(사용자의 질문)에 찰떡같이 맞아떨어지게 변형하세요.

[답변 절대 규칙]

1. 논리 차용: [예시]의 답변(A)이 가진 '핵심 억지 논리'를 파악하고, 그 패턴을 사용자의 질문에 맞춰 새롭게 변형하세요.
2. 길이 제한: 반드시 1~3문장 이내로 짧게 치고 빠지세요. (말이 길면 감점)
3. 태도: 상대방 말을 자르듯 뻔뻔하게 반박하고, 기상천외한 비유 하나만 특 던지세요.
4. 구어체: "아니,", "그게 아니라,", "제가 조사를 다 했어요." 같은 말을 적극 활용하세요.

[예시 1]

Q: (RAG로 찾은 과거 사용자 질문)

A: (RAG로 찾은 침착맨의 답변)

[사용자의 질문]

(현재 사용자가 한 말)

”

TTS 아바타 LLM의 답변을 음성으로 출력

API	OpenAI gpt-4o-mini	Elevenlabs turbo-v2
특징	성능 문제 無	성능 문제 無, 특정 인물 학습 기능 有
한계	기본 음성으로만 사용 가능	비용이 높음

⇒ Elevenlabs turbo-v2를 TTS API로 사용

Avatar 외모, 표정을 포함한 외형 출력

SIMLI(BAM-T)



ANAM(YARRR)



⇒ ANAM를 Avatar API로 사용

Service UI



침멀토론

침묵면과 1:1 토론을 시작해보세요!

토론하기

토론 주제 선택

오늘의 토론 주제를 선택해주세요

1

천한번이 더 강하다 vs 크리링이 더 강하다

2

물렁복숭아 vs 맥믹복숭아

3

민어 vs 아민, 어느 것으로 살 것인가?

4

유비 vs 조조, 누가 더 좋은 직장상사인가?

5

여름 vs 겨울, 평생 한 계절로 산다면?

6

사자 vs 호랑이, 복수의 왕은 누구인가?

7

야레 호병 vs 단발호병, 무엇이 진리인가?

8

음의 꼬리 vs 별의 머리, 무엇으로 사는 것이 좋은가?

9

가위 vs 바위 vs 보, 무엇이 유리한가?



WIN



이제 한번 닉 보세요

대화 내용이 없어서 승자를 판단하지 않습니다. 다음번 탈락자에게 복권해주세요!

LOSE



이제 한번 닉 보세요

승자: 침묵면 이후, 침묵면은 복숭아의 본질에 충실하다는 논리를 바탕으로 다양한 의견을 존중하며 대화를 이어갔다. 반면, '맥믹 복숭아'를 당기고 사용할 수 있다는 주장은 비

03

Demonstration



침멀토론

침착맨과 1:1 토론을 시작해보세요!

토론하기

04

Conclusion & Improvement

Conclusion & Limitation

전형적인 일반 대화형 인공지능을 넘어,
특정 인물의 페르소나를 학습한 아바타와 사용자가 상호작용하는 것이 가능한가?

⇒ “개인화된 페르소나 기반 아바타와의 상호작용은 기술적으로 구현 가능하다”

Limitation

1. 실시간 파이프라인의 지연 및 불안정성
2. 인물 데이터 사용에 대한 법적·윤리적 제약
3. 외부 API 및 서비스 의존성

Improvement

“당신의 연예인과 대화하고 싶지 않으신가요?”



Improvement

1. Market Size (보수적 추정)

TAM(Total Available Market): \$15B(약 22조 원 규모)

SAM(Serviceable Available Market): \$260M(약 4000억 원 규모)

SOM(Serviceable Obtainable Market): \$4M (약 60억 원 규모)


2. Business Model

B2C 수익화

- 이용 건당 결제
- 회당 500 KRW 내외

B2B 수익화

- B2B SaaS 솔루션
- CS, 교육 및 시뮬레이션, 영업 아바타



Improvement

1. 파이프라인 최적화 및 경량화

vLLM 등 고속 추론 엔진을 도입해 응답 속도를 대폭 단축하고, 끊임 없는 완벽한 실시간 아바타 상호작용을 구현 가능.

2. 자체 모델 내재화 (On-Premise) 구축

현재 의존 중인 외부 TTS 및 아바타 생성 API를 오픈소스 기반의 자체 모델로 대체하여, 서버 불안정성을 해소하고 운영 비용을 획기적으로 절감.

3. 장기 기억(Long-term Memory) 기반 토크타카 구현

사용자와의 과거 대화 내역을 기억하는 메모리 모듈을 탑재하여, 단발성 문답을 넘어 실제 토론처럼 자연스럽고 연속적인 상호작용을 완성.

Reference

- Dettmers, T., et al. (2023). QLoRA: Efficient Finetuning of Quantized LLMs. Advances in Neural Information Processing Systems (NeurIPS).
- Sellam, T., et al. (2020). BLEURT: Learning Robust Metrics for Text Generation. Association for Computational Linguistics (ACL).
- Zheng, L., et al. (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. Advances in Neural Information Processing Systems (NeurIPS).
- Wang, Z., et al. (2023). RoleLLM: Benchmarking, Eliciting, and Enhancing Role-Playing Abilities of Large Language Models. arXiv preprint arXiv:2310.00746.
- Shao, Y., et al. (2023). CharacterLLM: A Trainable Agent for Role-Playing. arXiv preprint arXiv:2310.10158.
- Park, J. S., et al. (2023). Generative Agents: Interactive Simulacra of Human Behavior. ACM Symposium on User Interface Software and Technology (UIST).